Projeto Preparação de Dados e KNN

CMC-13 Introdução a Ciência de Dados

Alunos:

- **João Pedro Couto Vieira**
- **Pedro de Oliveira Ramos**
- **Rafael Duarte Rocha**
- **Vinícius Ribeiro Rodrigues Camelo**

---

1. Preparação dos Dados

O dataset inclui avaliações de livros (0 a 10) feitas por vários usuários. Os dados estão divididos em três arquivos de dados tipo csv (comma separated values) tal como descrito abaixo. Os atributos de cada arquivo são os seguintes:

Arquivo sobre **usuário** ($users.csv$) com 20.702 usuários

- `user_id` : identificador do usuário (numérico)
- `age`,: idade do usuário
- `city`: Cidade do usuário (identificado por user_id)
- `state`: Estado do usuário
- `country`: País do usuário

Arquivo sobre **Livro** ($books.csv$) com 1.024 livros

- `isbn` : identificador do livro
- `book_title` - Título do livro em inglês,
- `book_author`: Nome do autor do livro
- `year_of_publication` : Ano de publicação do livro
- `publisher`,: Editora
- `img_l`: Link para imagem de capa do livro
- `Language`: Idioma no qual foi escrito o livro
- `Category`: Tipo de livro, observe que um livro pode pertencer a mais de um tipo (string)

Arquivo de **Avaliação** (*ratings.csv*) com 163.974 avaliações

- `isbn` : identificador do livro
- `user_id` : identificador do usuário que fez a avaliação (numérico)
- `rating`: avaliação do livro dado pelo usuário (0 a 10)

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder

# Load data
books = pd.read_csv("books.csv", delimiter=";")
users = pd.read_csv("users.csv", delimiter=";")
ratings = pd.read_csv("ratings.csv", delimiter=";")

# Join data in a single dataset
dataset = (
    ratings.join(users.set_index("user_id"), on="user_id")
    .join(books.set_index("isbn"), on="isbn")
    .sort_values(by="user_id")
)

dataset.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 163974 entries, 0 to 87424
Data columns (total 14 columns):
 #   Column               Non-Null Count   Dtype  
---  ------               --------------   -----  
 0   isbn                 163974 non-null  object 
 1   user_id              163974 non-null  int64  
 2   rating               163974 non-null  int64  
 3   age                  20702 non-null   float64
 4   city                 20680 non-null   object 
 5   state                20392 non-null   object 
 6   country              20037 non-null   object 
 7   book_title           163974 non-null  object 
 8   book_author          163974 non-null  object 
 9   year_of_publication  163974 non-null  float64
 10  publisher            163974 non-null  object 
 11  img_l                163974 non-null  object 
 12  Language             163974 non-null  object 
 13  Category             163974 non-null  object 
dtypes: float64(2), int64(2), object(10)
memory usage: 18.8+ MB
```

Após a união dos dataframes, ficamos com as seguintes colunas:

`isbn`, `user_id`, `rating`, `age`, `city`, `state`, `country`, `book_title`, `book_author`, `year_of_publication`, `publisher`, `img_l`, `Language`, `Category`

Para nossa análise, é importante mantermos atributos que possam ser comparáveis e descartar informações que são extremamente personalizadas. Para nosso objetivo de classificação via KNN, precisamos manter atributos que sirvam minimamente para a formação de clusters.

Assim, por essa lógica, podemos descartar imediatamente `user_id` e `isbn` que são identificadores únicos.

Além disso, podemos descartar os atributos de `city`, `state`. Estas podem ser úteis para algumas análises cujo tema geográfico é relevante, mas para a nossa análise, não é o caso.

Não estamos trabalhando com capa do livro como um atributo relevante, então podemos descartar `img_l`.

Percebemos que os atributos de `age` e `country` apresentam muitas informações faltantes, então optamos por descartá-los.

Nos resta, então, os atributos de `rating`, `book_title`, `book_author`, `year_of_publication`, `publisher`, `Language`, `Category`.

```
dataset = dataset.drop(columns=["user_id", "isbn", "city", "state",
"img_l", "age", "country"])
dataset.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 163974 entries, 0 to 87424
Data columns (total 7 columns):
 #   Column               Non-Null Count   Dtype
---  ------               --------------   -----
 0   rating               163974 non-null  int64
 1   book_title           163974 non-null  object
 2   book_author          163974 non-null  object
 3   year_of_publication  163974 non-null  float64
 4   publisher            163974 non-null  object
 5   Language             163974 non-null  object
 6   Category             163974 non-null  object
dtypes: float64(1), int64(1), object(5)
memory usage: 10.0+ MB
```

Vamos melhor avaliar alguns atributos específicos e verificar se os dados fazem sentido para nossa análise.

```
# dispersão dos dados por atributos
print(dataset['Language'].value_counts())
```

```
Language
en    108879
```

```
9      55095
Name: count, dtype: int64
```

Temos basicamente duas línguas e um dos inputs é "9", o que não faz sentido. **Podemos descartar esse campo.**

```
dataset = dataset.drop(columns=["Language"]) # Descartando a coluna Language

## Vamos avaliar por categoria agora
print(dataset['Category'].value_counts().head())
```

```
Category
['Fiction']                    90011
9                              55450
['Juvenile Fiction']            4196
['Biography & Autobiography']   3569
['Humor']                        883
Name: count, dtype: int64
```

```
# Vamos descartar os livros que têm "9" como atributo em categoria
dataset = dataset[dataset['Category'] != '9']

# Vamos tirar os colchetes e aspas do título
dataset['Category'] = dataset['Category'].str.replace('[','')
dataset['Category'] = dataset['Category'].str.replace(']','')
dataset['Category'] = dataset['Category'].str.replace("'",'')

# Aplicar a função lower() à coluna Category para trocar letras maiusculas por minusculas como 'HISTORY' e 'FICTION'
dataset['Category'] = dataset['Category'].str.lower()

# Set all 'fiction' like caregories into "fiction"
dataset['Category'] = dataset['Category'].apply(lambda x: 'fiction' if 'fiction' in x else x)

# Vamos avaliar por autor e editora agora
print(dataset['book_author'].value_counts())
print()
print('----------------------------------------')
print()
print(dataset['publisher'].value_counts())
```

```
book_author
John Grisham            3699
Nora Roberts            3270
Stephen King            3104
Rich Shapero            2502
Sue Grafton             2397
                        ...
```

```
JAMES CLAVELL               82
Bob Greene                  82
LAURELL K. HAMILTON         81
Lynne Reid Banks            81
Lilian Jackson Braun        81
Name: count, Length: 330, dtype: int64

----------------------------------------

publisher
Ballantine Books            10125
Berkley Publishing Group     7748
Dell                         4379
Pocket                       4339
Bantam                       4267
                            ...
Spectra Books                  87
Pan Books Ltd                  83
Quill                          83
Crimeline                      82
Downtown Press                 82
Name: count, Length: 126, dtype: int64
```

---

2. Análise Exploratória e Visualização dos Dados

```
sns.set_theme(style="whitegrid", palette="pastel", font_scale=1.2)

# Visualize the distribution of ratings and count of books by category
fig, axes = plt.subplots(2, 1, figsize=(10, 15))

# Distribution of ratings
sns.histplot(data=dataset, x='rating', kde=True, ax=axes[0],
color='blue')
axes[0].set_title('Distribution of Ratings', fontsize=16)
axes[0].set_xlabel('Rating', fontsize=14)
axes[0].set_ylabel('Count', fontsize=14)
axes[0].grid(True)

# Count of books by category
category_counts = dataset['Category'].value_counts()
top_categories = category_counts[:7]
other_categories_count = category_counts[7:].sum()
top_categories['Others'] = other_categories_count

sns.barplot(x=top_categories.index, y=top_categories.values,
ax=axes[1], palette='plasma')
axes[1].set_title('Count of Books by Category', fontsize=16)
axes[1].set_xlabel('Category', fontsize=14)
```

```
axes[1].set_ylabel('Count', fontsize=14)
axes[1].tick_params(axis='x', rotation=60)
axes[1].grid(True)

plt.tight_layout()
plt.show()
```

```
/var/folders/j3/85v9zb655rq94y5l71nq78nm0000gn/T/
ipykernel_79018/2874335391.py:19: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be
removed in v0.14.0. Assign the `x` variable to `hue` and set
`legend=False` for the same effect.

  sns.barplot(x=top_categories.index, y=top_categories.values,
ax=axes[1], palette='plasma')
```

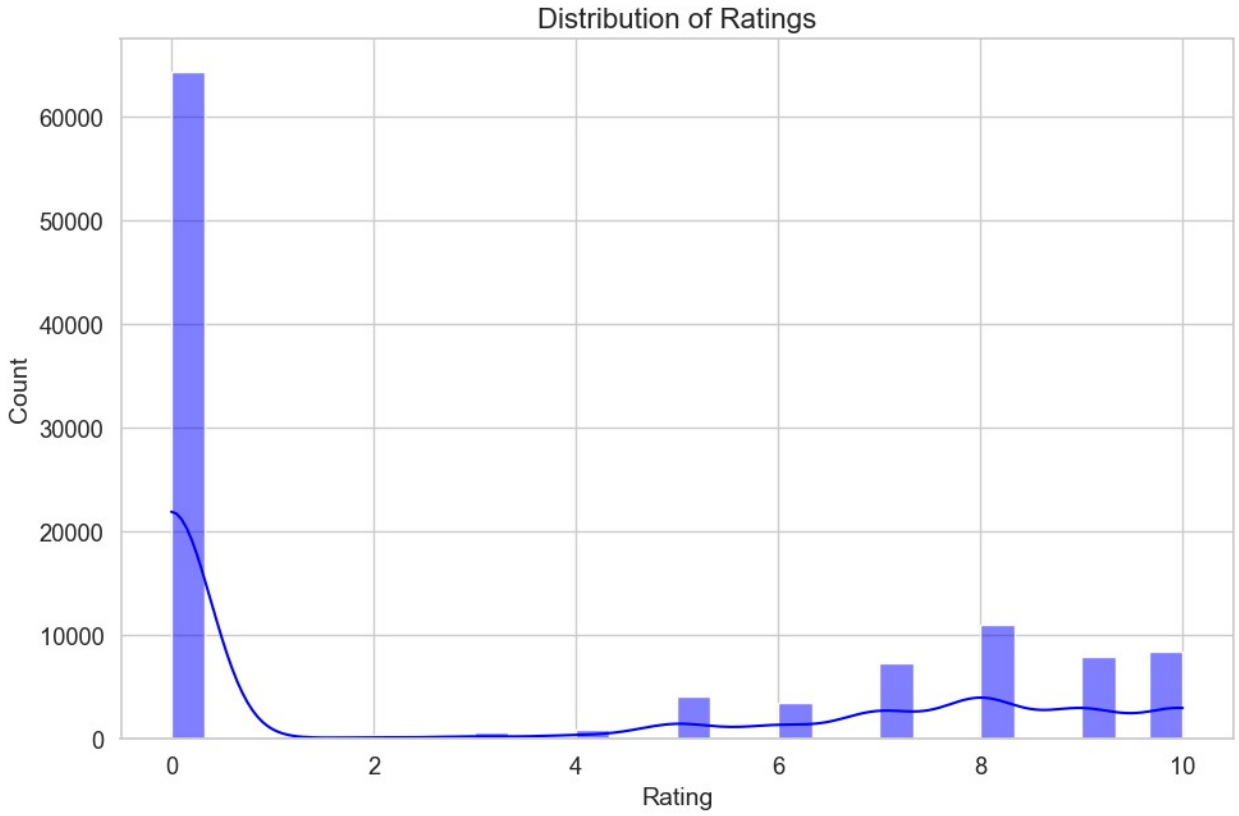
Distribution of Ratings
Count
Rating
0
10000
20000
30000
40000
50000
60000
0
2
4
6
8
10

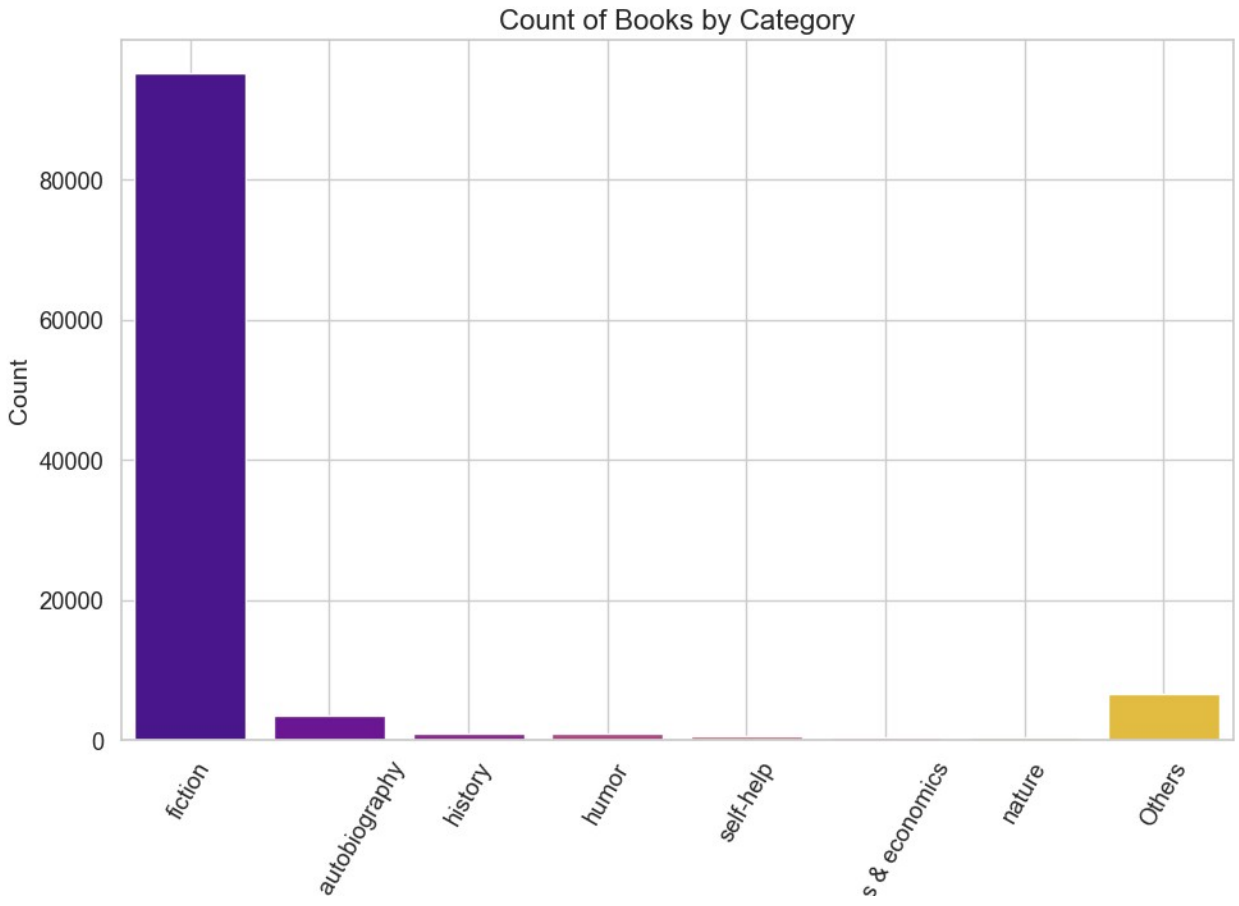
Count of Books by Category
Count
0
20000
40000
60000
80000
fiction
autobiography
history
humor
self-help
s & economics
nature
Others

Análise dos gráficos: Temos a grande parte dos nossos livros dentro da categoria de "Fiction", representando mais que 90% dos livros. Junto a isso, uma parte expressiva dos nossos dados se encontra com classificação 0.

```
# Count the number of books in each category
category_counts = dataset['Category'].value_counts()

# Get the top 15 categories
top_categories = category_counts[:15]

# Aggregate the other categories as 'others'
other_categories_count = category_counts[15:].sum()
top_categories['Others'] = other_categories_count

# Plot the ratings by category
fig, ax = plt.subplots(figsize=(12, 6))
sns.boxplot(data=dataset[dataset['Category'].isin(top_categories.index
)], x='Category', y='rating', ax=ax)

# Set the title, labels, and tick rotation
ax.set_title('Ratings by Category')
ax.set_xlabel('Category')
ax.set_ylabel('Rating')
ax.tick_params(axis='x', rotation=60)

plt.tight_layout()
plt.show()
```

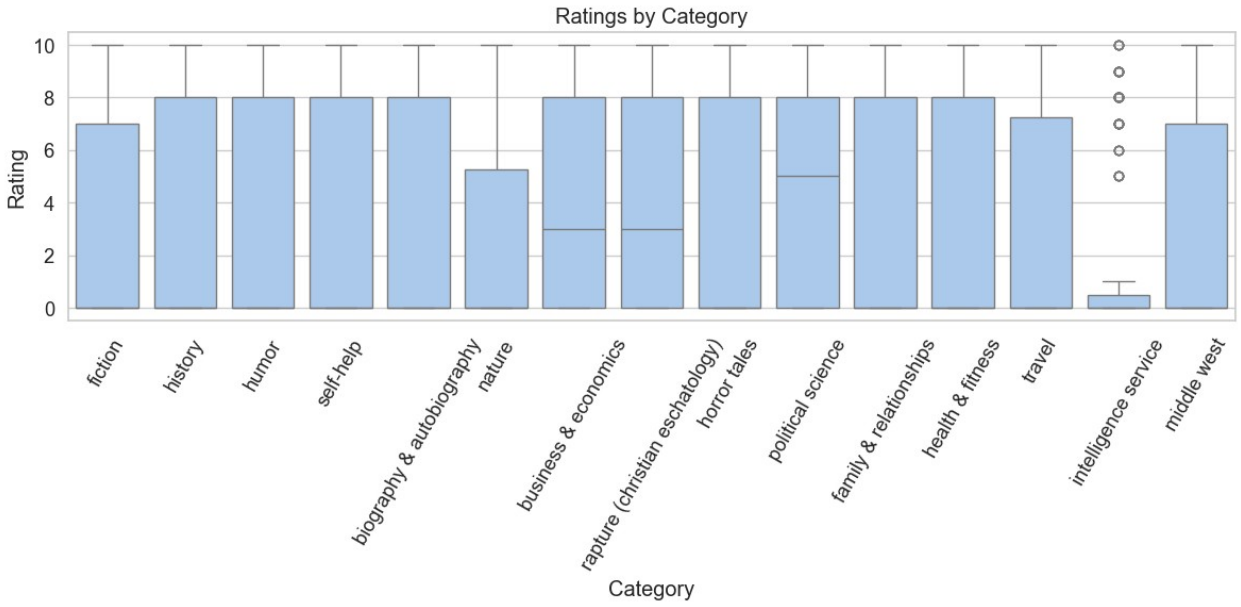

Recodificando os dados

É preciso recodificar os dados que sao do tipo 'string' para dados numéricos para que possa ser aplicado o algoritmo KNN. As colunas `book_title`, `book_author`, `publisher` e `category` receberão rótulos numéricos correspondentes a cada valor possível.

```
# Recodificando as colunas "book_title", "book_author", "publisher" e
"category"
label_encoder_title = LabelEncoder()
label_encoder_author = LabelEncoder()
label_encoder_publisher = LabelEncoder()
label_encoder_category = LabelEncoder()


dataset['book_title_encoded'] =
label_encoder_title.fit_transform(dataset['book_title'])
dataset['book_author_encoded'] =
label_encoder_author.fit_transform(dataset['book_author'])
dataset['publisher_encoded'] =
label_encoder_publisher.fit_transform(dataset['publisher'])
dataset['category_encoded'] =
label_encoder_category.fit_transform(dataset['Category'])
dataset_encoded = dataset[[
    'year_of_publication','book_title_encoded',
    'book_author_encoded','publisher_encoded',
    'category_encoded',
    'rating'
    ]]

dataset_encoded.head()
```

```
        year_of_publication  book_title_encoded  ...  category_encoded
rating
0                    1999.0                 565  ...                25
0
342                  1994.0                  64  ...                25
6
487                  2004.0                 634  ...                25
0
149412               2000.0                 584  ...                25
0
2501                 1997.0                  34  ...                25
9

[5 rows x 6 columns]
```

Normalizando as colunas para valores de 0 a 1

```
dataset_encoded = dataset_encoded/dataset_encoded.max()
dataset_encoded['rating'] = dataset['rating']
dataset_encoded.head()
```

```
        year_of_publication  book_title_encoded  ...  category_encoded
rating
0                  0.997505            0.878694  ...          0.531915
0
342                0.995010            0.099533  ...          0.531915
6
487                1.000000            0.986003  ...          0.531915
0
149412             0.998004            0.908243  ...          0.531915
0
2501               0.996507            0.052877  ...          0.531915
9

[5 rows x 6 columns]
```

Divindo a base de dados em treino e teste

```
from sklearn.model_selection import train_test_split

# Split the dataset into training (80%) and testing (20%) sets
train_set, test_set = train_test_split(dataset_encoded, test_size=0.2,
random_state=42)

# Print the shapes of the training and testing sets
print("Training set shape:", train_set.shape)
print("Testing set shape:", test_set.shape)

# Save the training and testing sets to CSV files
train_set.to_csv("dados_treinamento.csv", index=False)
test_set.to_csv("dados_teste.csv", index=False)
```

```
Training set shape: (86819, 6)
Testing set shape: (21705, 6)
```

---

3. Modelo baseado em KNN

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn import metrics

# Separate the features (X) and the target variable (y)
y_train = train_set["rating"]
X_train = train_set.drop(columns=["rating"],inplace=False)
```

```
y_test = test_set["rating"]
X_test = test_set.drop(columns=["rating"],inplace=False)

# Create the KNN classifier
knn = KNeighborsClassifier(n_neighbors=5)

# Train the model
model = knn.fit(X_train, y_train)

# Make predictions on the test set
y_pred = model.predict(X_test)

# Testing the acuracy with de training data
y_pred_train = model.predict(X_train)

# Train data model acuracy
accuracy_train = metrics.accuracy_score(y_train, y_pred_train)
print(f"Acurácia dados de treinamento: {100 * accuracy_train:.2f}%")

# Test data model acuracy
accuracy = metrics.accuracy_score(y_test, y_pred)
print(f"Acurácia dados de teste: {100 * accuracy:.2f}%")
```

```
Acurácia dados de treinamento: 55.94%
Acurácia dados de teste: 55.28%
```

Resultados de acurácia

A acurácia do modelo é baixa, apresenta resultados ligeiramente superiores a 50%.

Todavia, a acurácia avaliada com os dados de teste não é tão menor que a acurácia avaliada com os dados de treinamento. Isso é um bom indicativo de que o modelo generalizou bem os dados.

Foram realizados testes com diversos valores para o número de vizinhos mais próximos e para um número de vizinhos entre 5 e 20 o modelo tem diferenças menores que 2% de acurácia entre treino e teste.

---

4. Criando um modelo zero regra pela média dos dados

O modelo zero regra será composto somente pela média das avaliações para cada livro do dataset.

```
rating_means = train_set.groupby('book_title_encoded')
['rating'].mean().round(0)
rating_medians = train_set.groupby('book_title_encoded')
['rating'].median().round(0)
```

```
rating_modes = train_set.groupby('book_title_encoded')
['rating'].median().round(0)
```

Usando esse dataframe com as medias das avaliações é possível prever as avaliacoes usando o modelo zero-regra

```
# Verificando a acuracia do modelo para os dados de treinamento:

y_train_zero_rule = train_set['rating']
y_train_predicted = train_set['book_title_encoded']

zero_rule_train =
pd.merge(train_set[['book_title_encoded','rating']],rating_means,on='b
ook_title_encoded',how='left')
zero_rule_train.rename(columns={'rating_x': 'rating', 'rating_y':
'predicted'}, inplace=True)

# Acuracia para os dados de treinamento
accuracy_train = (zero_rule_train['rating'] ==
zero_rule_train['predicted']).mean()

# Verificando a acuracia do modelo para os dados de teste:

y_test_zero_rule = test_set['rating']
y_test_predicted = test_set['book_title_encoded']

zero_rule_test =
pd.merge(test_set[['book_title_encoded','rating']],rating_means,on='bo
ok_title_encoded',how='left')
zero_rule_test.rename(columns={'rating_x': 'rating', 'rating_y':
'predicted'}, inplace=True)

# Acuracia para os dados de treinamento
accuracy_test = (zero_rule_test['rating'] ==
zero_rule_test['predicted']).mean()

# Imprimindo resultados
print(f'Acurácia do modelo para dados de treino:
{100*accuracy_train:.3f}%')
print(f'Acurácia do modelo para os dados de teste:
{100*accuracy_test:.3f}%')
```

```
Acurácia do modelo para dados de treino: 0.657%
Acurácia do modelo para os dados de teste: 0.714%
```

Percebe-se que tanto para os dados de treino quanto para os dados de teste, o modelo tem acurácia menor que 1% nas previsões.

Criando modelo zero regra pela moda dos dados

```
# Verificando a acuracia do modelo para os dados de treinamento:

y_train_zero_rule = train_set['rating']
y_train_predicted = train_set['book_title_encoded']

zero_rule_train =
pd.merge(train_set[['book_title_encoded','rating']],rating_modes,on='b
ook_title_encoded',how='left')
zero_rule_train.rename(columns={'rating_x': 'rating', 'rating_y':
'predicted'}, inplace=True)

# Acuracia para os dados de treinamento
accuracy_train = (zero_rule_train['rating'] ==
zero_rule_train['predicted']).mean()


# Verificando a acuracia do modelo para os dados de teste:

y_test_zero_rule = test_set['rating']
y_test_predicted = test_set['book_title_encoded']

zero_rule_test =
pd.merge(test_set[['book_title_encoded','rating']],rating_modes,on='bo
ok_title_encoded',how='left')
zero_rule_test.rename(columns={'rating_x': 'rating', 'rating_y':
'predicted'}, inplace=True)

# Acuracia para os dados de treinamento
accuracy_test = (zero_rule_test['rating'] ==
zero_rule_test['predicted']).mean()

# Imprimindo resultados
print(f'Acurácia do modelo para dados de treino: {100 *
accuracy_train:.2f}%')
print(f'Acurácia do modelo para os dados de teste: {100 *
accuracy_test:.2f}%')
```

```
Acurácia do modelo para dados de treino: 53.41%
Acurácia do modelo para os dados de teste: 52.28%
```

---

5. Conclusões

Percebe-se que o modelo zero regra pela moda dos dados prevê consistentemente melhor que o modelo zero regra pela média dos dados. Isso provavelmente ocorreu devido ao desbalanceamento da base de dados com muitas avaliações com valor zero, fazendo com que a

moda dos dados prevesse melhor que a média. Apesar disso, o modelo zero regra pela moda dos dados têm acurácia abaixo do modelo utilizando o método classificador KNN.